

Visualisation de données massives par réduction de dimension non linéaire

Maxime Laborde, Clément Guerin, Mariette Dupuy

Université de Bordeaux

24 Mars 2020

- 1 Introduction
- 2 Principes de l'auto encoder
- 3 Explication ACP
- 4 Mise en situation sur l'auto-encoder et l'ACP

1 Introduction

2 Principes de l'auto encoder

3 Explication ACP

4 Mise en situation sur l'auto-encoder et l'ACP

- Présence de machine learning et du Deep learning de plus en plus important
- Comportement des algorithmes avec des paramètres spécifiques
- Auto encodeurs \rightarrow réseaux de neurones artificiels
- Efficacité d'une descente en dimension
- Comparaison des résultats ACP et Auto Encoder

1 Introduction

2 Principes de l'auto encoder

3 Explication ACP

4 Mise en situation sur l'auto-encoder et l'ACP

Principes de l'auto encoder

Dans toute la suite nous considérerons nos données sous la forme (X_i, Y_i) avec $i \in 1, \dots, n$

- $X_1, \dots, X_n \in \mathbb{R}^p$ avec p la dimension de nos données ($p=4$ dans le cas des iris)
- $Y_i \in 1, 2, \dots, k$ un ensemble de classe appelé l'étiquette de nos données.

Principes de l'auto encoder

- Extraire des données deux ensemble : un ensemble d'apprentissage et un ensemble test
- Réseau de Neurones → plusieurs couches de neurones → règle de passage → fonctions d'activation
- "fully connected" → connecte tous les neurones d'une couche à tous ceux de la suivante
- Nombre d'epochs → représente le nombre de fois que l'on souhaite que l'algorithme parcourt l'ensemble des données.
- Nombre de Batch → représente le nombre de données ou d'échantillons de données qu'il convient de parcourir avant de mettre à jour les paramètres du modèle

Ensemble d'apprentissage

L'algorithme va appliquer une certaine fonction à nos données et leur rajouter un biais :

$$X_i \rightarrow \sigma(W_1 X_i + b_1)$$

Avec W_1 taille $d \times p$ et $b_1 \in \mathbb{R}^d$

Passage de dimension p en dimension d (Iris $d=2$)

Nombre de répétitions de ce processus = Nombre couche de neurones

Dans la suite de la description du principe général nous supposons qu'il n'y a qu'une couche d'encodage.

Pour cela de manière analogue à la partie précédente nous allons transformer les données obtenues à l'issue de l'encodage en appliquant de nouveau une fonction puis un biais.

$$\sigma(W_1 X_i + b_1) \rightarrow \sigma(W_2 \sigma(W_1 X_i + b_1) + b_2)$$

Avec W_2 de dimension $p \times d$ ($p=4$ dimension initiale), et $b_2 \in \mathbb{R}^p$ représente le biais.

On peut réécrire cette équation sous la forme :

$$WX_i + b$$

Avec $W = W_2W_1$ et $b = W_2b_1 + b_2$

A l'issue de cette étape nous avons donc les données reconstruites.

Mean Squared Error \rightarrow minimiser la fonction suivante :

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n \|W_2(W_1X_i + b_1) + b_2 - X_i\|^2 \\ \iff \\ \frac{1}{n} \sum_{i=1}^n \|WX_i + b - X_i\|^2 \end{aligned}$$

Cette fonction est à minimiser sur ses arguments W_1 , W_2 , b_1 et b_2 .

- 1 Introduction
- 2 Principes de l'auto encoder
- 3 Explication ACP**
- 4 Mise en situation sur l'auto-encoder et l'ACP

Une première manière intuitive de voir l'ACP

Si $d=2$ on a :

$$w^1 \in \mathbb{R}^p \quad w^2 \in \mathbb{R}^p$$

avec $\langle w^1, w^2 \rangle = 0$ car ils doivent être orthogonaux

La formule à maximiser est la suivante :

$$\max_{w^1} \frac{1}{n} \sum_{i=1}^n \langle X_i, w^1 \rangle^2$$

Or on a que :

$$\langle X_i, w^1 \rangle^2 \iff w^{1t} X_i X_i^t w^1$$

Une première manière intuitive de voir l'ACP

En conséquence nous avons que

$$\max_{w^1} \frac{1}{n} \sum_{i=1}^n \langle Xi, w^1 \rangle^2 \iff \max_{w^1} \frac{1}{n} \sum_{i=1}^n w^{1t} Xi Xi^t w^1 \iff \max_{w^1} w^{1t} \Sigma w^1$$

avec Σ la matrice de covariance

Une autre manière de voir l'ACP qui permet de faire apparaître le lien avec les AE

L'objectif est de minimiser l'expression suivante :

$$\frac{1}{n} \sum_{i=1}^n \left\| \langle Xi, w^1 \rangle w^1 + \langle Xi, w^2 \rangle w^2 - Xi \right\|^2$$

$$\Longleftrightarrow$$

...

$$\Longleftrightarrow$$

$$\max_{w^1} w^{1t} \Sigma w^1 + \max_{w^2} w^{1t} \Sigma w^2$$

Lien entre AutoEncoder et ACP

Une de nos problématiques est de démontrer l'équivalence suivante :

$$\text{Autoencoder} \iff \text{ACP}$$

Pour observer un lien entre ces méthodes il est important de simplifier la deuxième formule de l'ACP.

$$\begin{aligned} & \left\| \langle Xi, w^1 \rangle w^1 + \langle Xi, w^2 \rangle w^2 - Xi \right\|^2 \\ & \iff \\ & \left\| w^1 w^{1t} Xi + w^2 w^{2t} Xi - Xi \right\|^2 \\ & \iff \\ & \left\| (w^1 w^{1t} + w^2 w^{2t}) Xi - Xi \right\|^2 \end{aligned}$$

On pose $W = w^1 w^{1t} + w^2 w^{2t}$. Avec W une matrice de rang 2.

On en conclut donc qu'il faut minimiser dans cette version la formule suivante :

$$\frac{1}{n} \sum_{i=1}^n \|WX_i - X_i\|^2$$

L'AutoEncoder lui a pour objectif de minimiser la formule suivante :

$$\frac{1}{n} \sum_{i=1}^n \|WX_i + b - X_i\|^2.$$

On peut donc constater que les deux formules sont similaires à un biais près.

Lien entre AutoEncoder et ACP

Optimisation :

L' ACP optimise sur des espaces très contraints \neq l'AutoEncoder optimise sans contrainte

De plus l'Auto encoder, ne rencontre aucun problème d'orthogonalité.



AutoEncoder	ACP
rang=1 ou rang=2	rang=2

$\text{Rang}(W) = 2$: permet d'observer une équivalence entre l'ACP et l'AE

- 1 Introduction
- 2 Principes de l'auto encoder
- 3 Explication ACP
- 4 Mise en situation sur l'auto-encoder et l'ACP



Jeu de donnée n°1 : Iris

Fonctions d'activation de type "linear" en entrée et en sortie



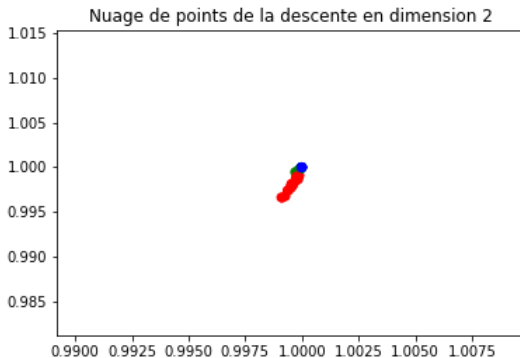
Jeu de donnée n°1 : Iris

Fonction d'activation d'entrée par la fonction "sigmoid"






Jeu de donnée n°1 : Iris

Fonction d'activation "sigmoid" en entrée et en sortie





Jeu de donnée n°2 : MNIST

Fonction d'activation "linear" en entrée et en sortie



Jeu de donnée n°2 : MNIST

Fonctions d'activation "sigmoid" en entrée et en sortie



Jeu de donnée n°2 : MNIST

Descente en dimension 32 avec une fonction "ReLU" en entrée et "sigmoid" en sortie :



Nous obtenons une perte de 0.02 , ce qui est un très bon résultat comme on peut le voir sur le graphique ci-dessus.